



Universidad Nacional Autónoma de México

Facultad de Ciencias



Proyecto de Tesis

- **Alumno:** Miguel Ángel Liera Montaña
- **Asesora:** Dra. Verónica Esther Arriola Ríos
Profesora Asociada C de TC.
Depto. de Matemáticas, Cub 119.
Facultad de Ciencias, UNAM.

Título

Análisis de Modelos de Redes Neuronales en la predicción de precios de las acciones en la BMV

Objetivo

Estudiar la transformada de ondícula (*wavelet transform*, DWT), sus propiedades y como alternativa a la transformada de Fourier (*Fourier Transform*) y otras técnicas en lograr una mejor descomposición de información en series de tiempo no estacionarias, además de mostrar sus ventajas como potenciadora del desempeño de las Redes Neuronales (*Artificial Neural Networks*, ANNs). Estudiar los principios de las Redes Neuronales Auto-regresivas no Lineales (*Not linear Autorregresive Neural Networks*, NARNNs) y las Redes Neuronales Recurrentes (*Recurrent Neural Networks*, RNNs), así como estructuras más complejas de estas: las Redes Neuronales Recurrentes con células de Memoria de Corto y Largo Plazo (*Long Short-term Memory*, LSTM) y Redes Neuronales con Unidades Recurrentes Cerradas (*Gated Recurrent Units*, GRU) en el pronóstico de datos de series de tiempo no estacionarias, y la elección de este último tipo por resolver el problema de dependencias de termino largo (*Long-Term Dependencies*). Analizar, diseñar, construir, evaluar y comparar el rendimiento de modelos compuestos de la DWT en conjunto con las NARNN, LSTM y GRU en la predicción de precios de cierre semanal en un tiempo t de acciones pertenecientes a empresas que cotizan de la Bolsa Mexicana de Valores, tomando como datos de entrada los valores de cierre de $t - 8$ días anteriores. Así mismo, evaluar el desempeño de los modelos al predecir el valor en t cuando los datos de entrada son generados por la misma red en iteraciones anteriores del proceso de predicción por el mismo. Mostrar que el modelo con mejor desempeño será el modelo DWT-RNN.

Justificación

Las redes neuronales comprenden un campo amplio en la Inteligencia Artificial y en consecuencia en las Ciencias de la Computación. Su utilidad va más allá de la investigación. Claramente tienen cabida en el ámbito financiero, en el análisis de crédito, la gestión de riesgos y el pronóstico de mercado (nuestro objeto de estudio). Este ha presentado un reto innegable por su alta volatilidad y el gran número de variables tanto económicas, políticas y sociales que intervienen en él. Así, se presenta una buena base para el estudio de las NARNNs y RNNs y la técnica de descomposición DWT. Existen varios referentes en la literatura de los cuales apoyarse, sin embargo, pocos se han enfocado en mostrar el potencial de los modelos recurrentes en el análisis del mercado mexicano, específicamente en el mercado de valores que comprende a entidades financieras nacionales (lista que veremos más adelante).

Descripción general

Se remarcará la importancia en la realización del proyecto y las razones de la elección del mercado de valores en México como fuente de datos. Se describirá las ideas que conforman de la descomposición de señales al igual que los conceptos fundamentales de la DWT y su selección en discriminación de técnicas como la transformada de Fourier y la transformada de Fourier de tiempo Reducido (*Short-time Fourier Transform*, STFT) debido a su propiedad de generar un análisis temporal y secuencial más detallado. Se fundamentarán principios, funcionamiento, desempeño y referentes de las NARNNs, LSTMs, y GRUs.

Se evaluará el desempeño de la arquitectura de DWT-NARNN presentada por Fathi, Asmaa Y. et al. [3] y LSTM presentada por Adusumilli, R. [1], y los modelos NARNN, DWT-LSTM, GRU, DWT-GRU en la predicción de series de tiempo no estacionarias conformadas por los precios de las acciones de empresas que han cotizado en la Bolsa Mexicana de Valores en un rango de tiempo que va de *01-01-2016* al *31-12-2023* a fin de mostrar englobar un espacio lo suficientemente amplio para que se puedan observar cambios significativos. Las empresas que tomaremos en cuenta para el estudio serán los precios de cierre semanal de las siguientes emisoras con clave y razón social:

- **ACTINVRB** CORPORACION ACTINVER, S.A.B. DE C.V.
- **BBAJIOO** BANCO DEL BAJÍO, S.A., INSTITUCIÓN DE BANCA MÚLTIPLE
- **BOLSAA** BOLSA MEXICANA DE VALORES, S.A.B. DE C.V.
- **CREAL** CREDITO REAL, S.A.B. DE C.V., SOFOM, E.N.R.
- **FINAMEXO** CASA DE BOLSA FINAMEX, S.A.B. DE C.V.
- **FINDEP** FINANCIERA INDEPENDENCIA, S.A.B. DE C.V. SOFOM, E.N.R.
- **GBMO** CORPORATIVO GBM, S.A.B. DE C. V.
- **GENTERA** GENTERA, S.A.B. DE C.V.
- **GFINBURO** GRUPO FINANCIERO INBURSA, S.A.B. DE C.V.
- **GFMULTIO** GRUPO FINANCIERO MULTIVA S.A.B. DE C.V.
- **GFNORTEO** GRUPO FINANCIERO BANORTE, S.A.B DE C.V.
- **GNP** GRUPO NACIONAL PROVINCIAL, S.A.B.
- **GPROFUT** GRUPO PROFUTURO, S.A.B. DE C.V.
- **INVEXA** INVEX CONTROLADORA, S.A.B. DE C.V.
- **PROCORP** PROCORP, S.A.B. DE C.V.
- **PV** PEÑA VERDE S.A.B.
- **Q** QUÁLITAS CONTROLADORA, S.A.B. DE C.V.
- **UNIFINA** UNIFIN FINANCIERA, S.A.B. DE C.V.
- **VALUEGFO** VALUE GRUPO FINANCIERO, S.A.B. DE C.V.

Estos datos se podrán recuperar del sitio *investing.com*.

Para la implementación, se tomarán los datos en lotes de ocho semanas como entrada para cada uno de los modelos obteniendo la predicción el valor de la acción en la novena semana. Después, se hará un corrimiento de uno en la serie, de manera que se tomaran las siguientes ocho semanas para predecir la consecuente novena y así sucesivamente. Aunado a este estudio, se tomarán únicamente los primeros ocho valores del conjunto de datos, de manera que en cada iteración de la predicción se integre el valor que se predijo en el paso anterior, así obteniendo el pronóstico de la semana t a partir de los $t - 8$ que son los que la red predijo en las ocho iteraciones anteriores.

Mencionado lo anterior, la combinación de una red recurrente y la técnica de DWT implica una mejora significativa a la capacidad de la red para capturar patrones en los datos. La DWT puede ayudar a resaltar características importantes como tendencias y patrones periódicos, lo que puede hacer que RNN sea más efectiva. Mientras que la red RNN presenta una ventaja ante los otros modelos por su estructura basada en recordar información importante y el estado de la celda (*cell state*), que permite que su unidad básica, la celda, procese nuevos datos con información de iteraciones anteriores, dando pie a un estudio mucho más detallado. Al utilizar la DWT como una técnica de preprocesamiento, una red recurrente puede concentrarse en aprender patrones de alto nivel en los datos descompuestos, lo que puede conducir a una mejor generalización y rendimiento en conjuntos de datos nuevos o desconocidos.

Temario

1. Introducción
2. Técnicas de descomposición de señales
3. Redes Neuronales para análisis de series de tiempo
 - a) Redes Neuronales Auto-regresivas
 - b) Redes Neuronales LSTM
 - c) Redes Neuronales GRU
4. Construcción del modelo
5. Proceso de entrenamiento
6. Evaluación de desempeño
7. Conclusiones

Referencias

- [1] Roshan Adusumilli. “Machine Learning to Predict Stock Prices”. En: *Towards Data Science* (2019). URL: <https://towardsdatascience.com/predicting-stock-prices-using-a-keras-lstm-model-4225457f0233>.
- [2] Kyunghyun Cho et al. “Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation”. En: *Association for Computational Linguistics* (2014). eprint: [arXiv:1406.1078](https://arxiv.org/abs/1406.1078).
- [3] Asmaa Y. Fathi, Ihab A. El-Khodary y Muhammad Saafan. “A Hybrid Model Combining Discrete Wavelet Transform and Nonlinear Autoregressive Neural Network for Stock Price Prediction: An Application in the Egyptian Exchange”. En: *Revue d’Intelligence Artificielle* 37.1 (feb. de 2023), págs. 15-21. DOI: [10.18280/ria.370103](https://doi.org/10.18280/ria.370103).
- [4] A. W. Galli, G. T. Heydt y P. F. Ribeiro. “Exploring the power of wavelet analysis”. En: *IEEE Spectrum* 9.4 (1996), págs. 0–41. DOI: [10.1109/67.539845](https://doi.org/10.1109/67.539845).
- [5] Felix A Gers, Jürgen Schmidhuber y Fred Cummins. “Learning to Forget: Continual Prediction with LSTM”. En: *Neural Computation* 12.10 (2000), págs. 2451-2471. DOI: [10.1162/089976600300015015](https://doi.org/10.1162/089976600300015015).
- [6] Sepp Hochreiter y Jürgen Schmidhuber. “Long Short-Term Memory”. En: *Neural Computation* 9.8 (1997), págs. 1735-1780. DOI: [10.1162/neco.1997.9.8.1735](https://doi.org/10.1162/neco.1997.9.8.1735).
- [7] Deniz Kenan Kılıç y Ömür Uğur. “Hybrid wavelet-neural network models for time series”. En: *Applied Soft Computing* 144 (2023), pág. 110469. ISSN: 1568-4946. DOI: [10.1016/j.asoc.2023.110469](https://doi.org/10.1016/j.asoc.2023.110469). URL: <https://www.sciencedirect.com/science/article/pii/S1568494623004878>.
- [8] Deniz Kenan Kılıç y Ömür Uğur. “Hybrid wavelet-neural network models for time series”. En: *Applied Soft Computing* 144 (2023), pág. 110469. ISSN: 1568-4946. DOI: <https://doi.org/10.1016/j.asoc.2023.110469>. URL: <https://www.sciencedirect.com/science/article/pii/S1568494623004878>.
- [9] S G Mallat. “A theory for multiresolution signal decomposition: The wavelet representation”. En: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 11.7 (1989), págs. 674-693. DOI: [10.1109/34.192463](https://doi.org/10.1109/34.192463).